



Gerçek Zamanlı İskelet Tabanlı Şiddet Tespiti

Proje Raporu — Görüntü İşleme Dersi

Üniversite: Pamukkale Üniversitesi

Bölüm: Bilgisayar Mühendisliği

Ders: Görüntü İşleme

Tarih: Mayıs 2026

İçindekiler

1. Projenin Amacı ve Motivasyon
2. Sistem Mimarisi
3. Veri Seti ve Ön İşleme Pipeline'ı
4. Model Tasarımı — GRU Mimarisi
5. Eğitim Süreci
6. Deneysel Sonuçlar
7. Ablasyon Çalışmaları
8. Gerçek Zamanlı Çıkarım Sistemi
9. Geliştirme Süreci — Yaşananlar
10. Kısıtlamalar ve Gelecek Çalışmalar
11. Sonuç
12. Kaynakça

1. Projenin Amacı ve Motivasyon

Bu proje, canlı kamera veya video akışından insan iskeletlerini çıkararak **Violence / NonViolence** ikili sınıflandırması yapan, hafif ve gerçek zamanlı bir görüntü işleme sistemi

geliştirmeyi hedeflemektedir.

Neden İskelet Tabanlı Yaklaşım?

Klasik piksel tabanlı şiddet tespiti yerine iskelet tabanlı bir yaklaşımın seçilmesinin iki temel gerekçesi vardır:

Gerekçe	Açıklama
Gizlilik	Model kişinin yüzünü veya kıyafetini değil, yalnızca hareket geometrisini görür
Sağlamlık	Işık değişimi, arka plan karmaşıklığı ve renk farklılıkları modele daha az yansır

Sistem Gereksinimleri

- Düşük gecikme süresiyle gerçek zamanlı karar üretimi
- Hafif model mimarisi (CPU'da bile çalışabilmeli)
- Gizlilik-dostu iskelet temsili
- Eğitim ve servis arasında sıfır drift (eğitimde kullanılan ön işleme = canlıda kullanılan)

2. Sistem Mimarisi

Sistem iki temel faza ayrılmıştır. Bu ayrım bilinçli ve kritik bir tasarım kararıdır.

OFFLINE PREPROCESSING (Kaggle GPU)

[Ham Video] → 10 FPS Örnekleme

→ Koşullu CLAHE → Gaussian 3×3 → 640×640

→ BGR→RGB → YOLOv8n-Pose

→ Top-2 Kişi (bbox alana göre, X-sıralı)

→ Hip Centering + Shoulder-Hip Ölçekleme

→ 69-boyutlu özellik vektörü / frame

→ 30-frame kayan pencereler (stride=15)

→ Motion Filter $\theta=0.05$ (yalnızca Violence)

↓

(N, 30, 69) .npy dizileri

↓

GRU SINIFLANDIRICI (Eğitim)

2-katmanlı GRU (128→64) + Dropout 0.3 + Dense 32

BCELoss + Adam optimizer, max 100 epoch

Early stopping (val_loss tabanlı)

↓

models/best_model.pt

↓

ONLINE INFERENCE (Gerçek Zamanlı)

[Canlı Kamera/Video]

→ Aynı Frame Ön İşleme

→ Pose Kalite Kapısı (6+ keypoint, 2+ torso, $\text{bbox} \geq 0.02$)

→ FIFO Buffer (30 frame)

→ GRU → Sigmoid olasılığı

→ Üç-Bölgeli Karar ($t=0.45$):

$p < 0.35$ → NonViolence

$0.35-0.45$ → Suspicious

$p \geq 0.45$ → Violence

→ Zamansal Yumuşatma (3-pencere çoğunluk oyu)

→ Giriş Baskılama (yeni kişide 30f ısınma)

3. Veri Seti ve Ön İşleme Pipeline'ı

3.1 Veri Seti


Proje iki veri setinin harmanlanmasıyla oluşturulan bir eğitim kümesi kullanmaktadır.

Veri Seti	Video Sayısı	Kullanım
RLVS (Real Life Violence Situations)	2000	Train + Val + Test
RWF-2000	2000	Train + Val (test dahil değil)

Important

Test seti yalnızca RLVS kaynaklıdır. Bu sayede RWF-2000 eklenmeden önceki baseline ile doğrudan karşılaştırma yapılabilir.

3.2 Veri Dağılımı



Split	Toplam Dizi	Violence	NonViolence	Kaynak
Train	6,423	3,227	3,196	RLVS + RWF-2000
Val	1,435	683	752	RLVS + RWF-2000
Test	740	277	463	Yalnızca RLVS

Sınıf Dengeleme: Motion filter, Violence pencerelerinin bir kısmını elediğinden oluşan dengesizliği gidermek için train setinde NonViolence altörnekleme uygulanmıştır.

3.3 Frame Ön İşleme — Kilitli Pipeline

Her frame hem offline hem de online aşamada **aynı** sırayla işlenir:

```

Step 1 → CLAHE (Koşullu – yalnızca karanlık/düşük kontrastlı framelere)
Step 2 → Gaussian Blur 3×3 (sensor gürültüsü için)
Step 3 → Resize 640×640 (YOLOv8n-Pose giriş boyutu)
Step 4 → BGR → RGB (OpenCV BGR, PyTorch RGB bekler)

```

Note

Bu sıra değiştirilemez. Eğitim ve canlı kullanım arasındaki **train/serve skew**'ü sıfırlamak için birebir aynı modül her iki fazda da kullanılmaktadır.

CLAHE neden koşullu? Zaten iyi aydınlatılmış framelere CLAHE uygulamak yapay dokular yaratır ve YOLOv8n-Pose'un keypoint güvenini olumsuz etkileyebilir.

Gaussian Blur neden 3×3? Gözetleme kameralarındaki baskın gürültü tipi Gaussian (sensör ısı, düşük ışık) olduğundan Gaussian Blur doğru eşleşmeyi sağlar. Bilateral Filter daha iyi kenar koruma sağlar, ancak gerçek zamanlı kullanım için çok yavaştır.

3.4 Poz Çıkarımı ve Özellik Vektörü

YOLOv8n-Pose her kişi için 17 COCO keypoint üretir. Sahnede birden fazla kişi varsa bounding box alanına göre en büyük iki kişi seçilir ve X eksenine göre sıralanır.

69-boyutlu özellik vektörü:

Kişi 1 iskeleti: 17 keypoint $\times$ 2 koordinat = 34 boyut
Kişi 2 iskeleti: 17 keypoint $\times$ 2 koordinat = 34 boyut
İnteraksiyon: Normalize bbox merkez mesafesi = 1 boyut
Toplam: 69 boyut

Normalizasyon: Her kişi için:

1. **Hip Centering** — kalça orta noktası orijine taşınır (pozisyon bağımsızlığı)
2. **Shoulder-Hip Scaling** — torso uzunluğuna bölünür (ölçek bağımsızlığı)

Kayan Pencere: 30-frame pencere, stride=15 ile kaydırılır $\rightarrow$ ~3 saniyelik hareket dizisi.

Eğitimde stride=15 kullanılırken online inference'da her yeni frame GRU'yu tetikler (stride=1); bu sayede gerçek zamanlı karar gecikmesi minimize edilir.

Motion Filter: Violence pencerelerine, ortalama normalize keypoint L2 deplasmanı $\theta=0.05$ altında olanlar eğitimden çıkarılır. Bu, video düzeyindeki etiket gürültüsünü (şiddet videosunun sakın başlangıç/bitiş kısımları) azaltır.

4. Model Tasarımı — GRU Mimarisi

4.1 Neden GRU?

Mimari	Temporal Hafıza	Parametre	Eğitim Hızı	Seçim
Vanilla RNN	Var (zayıf)	Az	Hızlı	$\times$ — vanishing gradient
LSTM	Var (güçlü)	Fazla	Yavaş	$\times$ — gereksiz karmaşıklık
GRU	Var (güçlü)	Orta	Hızlı	✓ Seçilen
Transformer	Var (global)	Çok fazla	Çok yavaş	$\times$ — 10K dizi için overkill

Mimari	Temporal Hafıza	Parametre	Eğitim Hızı	Seçim
3D CNN	Var (lokal)	Fazla	Yavaş	$\times$ — ham piksel gerektirir

GRU, LSTM'in sadeleştirilmiş versiyonudur. 4 kapı (LSTM) yerine 2 kapı (Update Gate + Reset Gate) kullanır, parametre sayısı LSTM'in yaklaşık %75'idir. Bu veri boyutunda (~10K dizi) GRU genellikle LSTM ile eşdeğer performans gösterir.

4.2 Model Mimarisi

INPUT	(batch, 30, 69)
GRU L1	GRU(69→128) ← return_sequences=True
Dropout	p = 0.3
GRU L2	GRU(128→64) ← return_sequences=False (son adım)
Dropout	p = 0.3
Dense	Linear(64→32) + ReLU
Output	Linear(32→1) + Sigmoid → P(Violence) ∈ [0,1]

Toplam Parametre Sayısı: 115,777 — CPU'da bile gerçek zamanlı çalışmaya yeterince hafif.

4.3 Eğitim Konfigürasyonu

Parametre	Değer	Gerekçe
Loss	BCELoss	İkili sınıflandırma için matematiksel doğru seçim
Optimizer	Adam (lr=1e-3)	Adaptif lr, recurrent mimarilerde kararlı
Weight	1e-4	L2 regularizasyon, overfitting'e karşı


Parametre	Değer	Gerekçe
Decay		
Scheduler	ReduceLROnPlateau (p=5, f=0.5)	Loss platoya ulaşınca lr yarıya iner
Max Epoch	100	Early stopping zaten keser
Batch Size	32	GPU belleği ve gradient gürültüsü dengesi
Early Stop	val_loss, patience=10	En düşük val_loss → best model
Gradient Clip	max_norm=1.0	GRU exploding gradient koruması

5. Eğitim Süreci

5.1 Donanım Ortamı

- **Ön İşleme:** Kaggle GPU (ücretsiz tier — telefon doğrulaması gerekti)
- **Model Eğitimi:** RTX 4060 Laptop GPU (CUDA 12.6)
- **Geliştirme:** Python 3.13 + PyTorch 2.12.0+cu126
- **Hız:** Epoch başına ~10-11 saniye (GPU ile ~5.6× hızlanma)

5.2 Eğitim Eğrileri



Gözlemler:

- Eğitim 17 epoch'ta tamamlandı (Early stopping patience=10 ile tetiklendi)
- En iyi val_loss → **Epoch 7** (val_loss=0.5314)
- Epoch 7'den sonra val_loss artarken train_loss düşmeye devam etti → **Overfitting başladı**
- LR, Epoch 14'te 1e-3'ten 5e-4'e indi (ReduceLROnPlateau patience=5 devreye girdi)
- Validasyon accuracy'si en yüksek **~76%**'ya ulaştı (Epoch 11)

5.3 Final Blended Model Eğitimi

RLVS ve RWF-2000 veri setlerinin harmanlanmasıyla yeniden eğitilen final model:

Parametre	Değer
Toplam Epoch	17
En İyi Epoch	7 (early stopping patience=10)
En İyi val_loss	0.5314
Donanım	RTX 4060 Laptop GPU (CUDA 12.6)
Test F1	0.820 @ t=0.45
Test AUC-ROC	0.927

5.4 Data Augmentation Denemesi (Başarısız)


İlk model eğitiminde F1 iyileştirmek amacıyla 4 katlı veri artırma denenmiştir:

- Gaussian gürültü ekleme
- Zamansal kaydırma
- Dizi ters çevirme

Sonuç: 3283 dizi → 13K dizi. Ancak daha hızlı overfitting gözlemlendi, F1'de iyileşme olmadı. Neden? Artırılmış örnekler orijinallerine çok benziyordu. Karar → **Orijinal veriye geri dönüldü.**

6. Deneysel Sonuçlar

6.1 Final Model — Confusion Matrix




Test Seti: 740 dizi (277 Violence, 463 NonViolence) — RLVS only, threshold=0.45

	Tahmin: Violence	Tahmin: NonViolence
Gerçek: Violence	TP = 255	FN = 22

	Tahmin: Violence	Tahmin: NonViolence
Gerçek: NonViolence	FP = 93	TN = 370

6.2 Performans Metrikleri




Metrik	Değer	Yorum
Precision	0.775	100 alarm'dan 77'si gerçek
Recall	0.870	Gerçek vakaların %87'si yakalandı
F1	0.820	Precision ve Recall dengesi
AUC-ROC	0.927	Eşik bağımsız ayırt edicilik — çok güçlü
Accuracy	85.7%	Genel doğruluk

💡 Tip

Gözetleme uygulamalarında Accuracy tek başına yanıltıcı olabilir. AUC-ROC=0.927 değeri, modelin Violence ve NonViolence dağılımlarını çok iyi ayırt ettiğini göstermektedir.

6.3 Threshold Analizi



- Başlangıç eşiği **t=0.7** (kaynak PDF'den) — çok muhafazakâr: Recall=0.54


- RLVS-only modelde val setinde ayarlanan eşik: **t=0.40** — F1=0.827
- Blended modelde yeniden ayarlanan eşik: **t=0.45** — F1=0.820 (**dağıtılan değer**)

Üç-Bölgeli Karar Sistemi:

- $p < 0.35$ → **NonViolence** (güvenli)
- $0.35 \leq p < 0.45$ → **Suspicious** (erken uyarı)
- $p \geq 0.45$ → **Violence** (alert)

7. Ablasyon Çalışmaları

Toplam **4 ana ablasyon kategorisi** gerçekleştirilmiştir. Her ablasyon, yalnızca tek faktör değiştirilerek yapılmıştır.



7.1 Threshold Ablasyonu (P7.1)

Eşik	Precision	Recall	F1	Karar
0.30	0.680	0.985	0.806	Çok fazla FP
0.40	0.744	0.931	0.827	RLVS-only için dağıtıldı
0.45	0.775	0.870	0.820	Blended model için dağıtıldı

Eşik	Precision	Recall	F1	Karar
0.70	0.867	0.542	0.667	Başlangıç değeri — çok muhafazakâr

Bulgu: Kaynak PDF'deki başlangıç eşiği 0.7, düşük Recall (54%) nedeniyle gerçek kullanım için uygun değildir. Val setinde ayarlama yapıldığında 0.45 en iyi F1'i vermektedir.

7.2 İnteraksiyon Özelliği Ablasyonu (P7.2)

Konfigürasyon	F1	AUC-ROC	$\Delta F1$
69-dim (interaction dahil)	0.820	0.927	baseline
68-dim (interaction çıkarıldı)	0.825	0.931	+0.005

Bulgu: İnteraksiyon özelliği olmadan model marjinal olarak daha iyi F1 (+0.005) gösteriyor. Ancak fark istatistiksel olarak anlamlı değil ve özellik tasarım kararı kilitli (D13) — 69-dim korundu.

7.3 Normalizasyon Ablasyonu (P7.3)

Konfigürasyon	F1	AUC-ROC	$\Delta F1$
Tam norm (hip+scale)	0.820	0.927	baseline
Normalizasyon yok	0.827	0.938	+0.007
Yalnızca hip centering	0.823	0.937	+0.003
Yalnızca ölçekleme	0.819	0.925	-0.001

Bulgu: Tüm varyantlar $\pm 1\%$ F1 aralığında. Normalizasyon, Precision/Recall dengesinde en iyi sonucu veriyor. Tam normalizasyon korundu.

7.4 Motion Filter Ablasyonu (P7.4)

θ Değeri	F1	AUC-ROC	$\Delta F1$	Dizi Sayısı
$\theta=0.00$ (filtre kapalı)	0.831	0.923	+0.011	6,493

θ Değeri	F1	AUC-ROC	$\Delta F1$	Dizi Sayısı
$\theta=0.025$	0.819	0.919	-0.001	6,428
$\theta=0.05$ (baseline)	0.820	0.927	baseline	6,423
$\theta=0.075$	0.798	0.923	-0.022	6,421
$\theta=0.10$	0.830	0.931	+0.010	6,420

Bulgu: Motion filter'ın etkisi marjinaldir. $\theta=0.05$ dengeli bir değerdir, korundu.

7.5 RWF-2000 Veri Seti Harmanlaması (P8)

Model	Eğitim Verisi	F1	AUC-ROC	Threshold
Baseline	RLVS 3,283 dizi	0.827	0.921	0.40
Blended	RLVS+RWF 6,423 dizi	0.820	0.927	0.45

Bulgu: Blended model F1'de 0.7 puan kayıpla AUC-ROC'da +0.6 puan kazanmaktadır. AUC-ROC iyileşmesi, modelin eşik bağımsız ayırt ediciliğinin arttığına işaret etmektedir. Blended model dağıtımda tercih edildi.

8. Gerçek Zamanlı Çıkarım Sistemi

8.1 Online Inference Pipeline

Canlı kullanımda aşağıdaki adımlar gerçek zamanlı olarak çalışır:

- Frame Ön İşleme** — offline ile aynı pipeline (CLAHE → Blur → Resize → RGB)
- Pose Kalite Kapısı** — Yeni kararlar:
 - En az **6 geçerli keypoint** (conf ≥ 0.5)
 - En az **2 torso keypointi**
 - Bbox alan oranı ≥ 0.02
 - Bu koşulları sağlamayan frame'ler: buffer temizlenir, **No Valid Pose** gösterilir
- FIFO Buffer** — 30 frame'lik halka tamponu (inference stride=1; eğitimde stride=15 idi)

4. **GRU Forward Pass** — Buffer dolduğunda her yeni frame'de tetiklenir
5. **Üç-Bölgeli Karar** — Sigmoid olasılığına göre NonViolence/Suspicious/Violence
6. **Zamansal Yumuşatma** — Son 3 kararın çoğunluk oyu (tek-frame gürültüsünü bastırır)
7. **Giriş Baskılama** — Sahneye yeni kişi girdiğinde 30 frame ısınma süresi

8.2 Pose Kalite Kapısının Motivasyonu

Note

Bu bileşen, proje geliştirme sürecinde keşfedilen bir soruna yanıt olarak eklendi.

Webcam testi sırasında kullanıcı, kameraya yalnızca yüzünü gösterdiğinde sistemin yanlışlıkla "Violence" kararı verdiğini fark etti. Bunun nedeni, kısmi baş/profil tespitlerinin geçersiz vücut pozu geometrisi üretmesi ve GRU'yu yanıltmasıydı.

Çözüm: GRU çıkarımına girişi kontrol eden bir kalite kapısı eklendi (D26). Böylece yalnızca geçerli, tam vücut pozu olan frameleer modele verilir.

8.3 Kullanıcı Arayüzü

OpenCV bilgi paneli:

- Kamera görüntüsü + 320px karanlık kenar panel
- Karar renk kodu (kırmızı/sarı/yeşil)
- Olasılık çubuğu ve eşik işareti
- Buffer/FPS/pose durumu
- Basitleştirilmiş çubuk-figür skeleton diyagramı
- Son 10 kararın zaman damgalı geçmişi

9. Geliştirme Süreci — Yaşananlar

Proje sıfırdan tamamlanmıştır. İşte geliştirme adımlarının hikayesi:

9.1 P0–P2 — Bootstrap ve Kaggle Notebook

P0 — Proje İskeleti:

- Repository yapısı, `configs/config.py` , `requirements.txt` , virtual environment
- Tüm kilitli sabitler `decision_log.md` 'den config'e işlendi
- PyTorch 2.12.0 (CPU) + OpenCV 4.13.0 + Ultralytics 8.4.51

P1+P2 — Kaggle Notebook:

- 14 hücreli tam pipeline notebook oluşturuldu
- **Sorun yaşandı:** Kaggle, nbformat 4.5 ile cell `id` alanlarını okuyamıyordu
- **Çözüm:** nbformat_minor=4'e düşürüldü, tüm `id` alanları silindi
- **Başka sorun:** Kaggle GPU erişimi için telefon doğrulaması gerekiyordu → tamamlandı

P3+P4+P5+P6 — Local Kod Tabanı:

- `ViolenceGRU` modeli, eğitim, değerlendirme ve inference scriptleri
- Smoke test başarılı: `(32,30,69)→(32,1)` şekil kontrolü

9.2 P4–P5 — İlk Model Eğitimi ve Ablasyon

P4 — İlk Model Eğitimi:

- Epoch 8'de en iyi `val_loss=0.4837`
- xviii. epoch'ta early stopping tetiklendi
- Val accuracy ~79.9% — umut verici!
- **Sorun:** Epoch 9'dan itibaren overfitting gözlemlendi

P5 — Değerlendirme + P7.1 Threshold Ablasyonu:

- Test F1=0.827 @ `t=0.40` (val-tuned)
- 4× veri artırma denendi → BAŞARISIZ (daha hızlı overfitting, F1 artışı yok)
- **Karar:** Orijinal 3283 diziye geri dönüldü

9.3 P8 — RWF-2000 Harmanlaması

P8.1 — Kaggle Notebook Güncelleme:

- `BLEND_RWF=True` bayrağı, Fight→Violence/NonFight→NonViolence etiket dönüşümü
- **Sorun:** RWF-2000 Kaggle path'i yanlıştı → düzeltildi
- Sonuç: train %96 artış (3283→6423 dizi)

P8.2 — GPU Ortamı ve Blended Model Eğitimi:

- RTX 4060 için CUDA 12.6 kuruldu
- **Sorun:** Globalde CPU-only PyTorch vardı → kaldırıldı, venv'e CUDA sürümü kuruldu
- Blended model: 17 epoch, F1=0.820, AUC=0.927 @ t=0.45

P7.2 — Interaction Feature Ablasyonu + Dokümantasyon Senkronizasyonu:

- 68-dim model → F1=0.825 (+0.005 vs baseline) — fark önemsiz
- 69-dim korundu (D13 kararı kilitli)
- 8+ TBD [state.md](#)'de çözümlendi
- D21-D26 kararları decision_log.md'ye eklendi

9.4 P9 — Canlı Test ve OpenCV Panel Geliştirme

Webcam Testi:

- Sistem canlı webcam ile başarıyla çalıştı
- **Kritik Sorun Keşfedildi:** Kameraya yalnızca yüz gösterildiğinde sistem Violence kararı veriyordu!
- **Analiz:** Kısmi baş/profil pozu, geçersiz iskelet geometrisi üretiyordu
- **Çözüm (D26):** Online pose kalite kapısı eklendi (6 keypoint + 2 torso + bbox≥0.02)

P9 — OpenCV Info Panel:

- Saf OpenCV + numpy ile profesyonel kenar panel oluşturuldu
 - Karar rengi, olasılık çubuğu, skeleton diyagramı, karar geçmişi
 - Harici bağımlılık eklenmedi
-

10. Kısıtlamalar ve Gelecek Çalışmalar

#	Kısıtlama	Etki	Gelecek Çözüm
L1	İki kişi üst sınırı	Kalabalık sahnelerde bilgi kaybı	Değişken boyutlu vektör veya 3+ kişi desteği
L2	X-eksenine göre sıralama kararsızlığı	Kişiler çakıştığında kimlik değişimi	ByteTrack veya IoU tracker
L3	Video düzeyinde etiket gürültüsü	Mislabeled pencereler eğitimi bozar	Pencere düzeyinde etiketleme
L4	Yalnızca iskelet temsili	Silah, kan, nesne görünmez	Piksel dalı füzyonu
L5	Sabit 30-frame pencere	3 saniye altı olaylar seyreltilir	Değişken uzunluk desteği
L6	Domain shift	YouTube→güvenlik kamerası farkı	Çok kaynaklı veri, domain adaptation

11. Sonuç

Bu proje, görüntü işlemenin temel tekniklerini (CLAHE, Gaussian blur, renk uzayı dönüşümü, resize) ile ileri düzey makine öğrenmesi bileşenlerini (YOLOv8n-Pose, GRU zaman serisi modeli) bir araya getirerek gerçek zamanlı çalışabilen uçtan uca bir sistem ortaya koymuştur.

Temel Başarılar

Alan	Sonuç
AUC-ROC	0.927 — mükemmel ayırt edicilik
F1	0.820 — dengeli Precision/Recall
Model Boyutu	115,777 parametre — CPU'da gerçek zamanlı

Alan	Sonuç
Gerçek Zamanlı	~5-10 FPS (CPU), GPU ile daha hızlı
Gizlilik	Piksel değil iskelet — gizlilik dostu

Öğrenilen Dersler

- Eşik seçimi kritiktir.** Kaynak PDF'deki $t=0.7$ pratikte çok muhafazakârdır; val setinde ablasyon yapmak zorunludur.
- Veri artırma her zaman işe yaramaz.** Orijinallerine çok benzeyen örnekler overfitting'i artırabilir.
- RWF-2000 harmanlaması AUC'yi iyileştirdi.** Çeşitli kamera açıları ve aydınlatma koşulları modelin genel ayırt ediciliğini artırdı.
- Canlı test kritik geri bildirim sağlar.** Kısmi pose sorunu, yalnızca webcam testinde ortaya çıktı ve pose kalite kapısı (D26) bu geri bildirimin ürünüdür.
- Offline/online faz ayrımı şarttır.** Aynı feature builder'ın her iki fazda kullanılması train/serve drift'ini sıfırlar.

Görüntü İşleme Dersi Kapsamında Öğrenilen Konular

Bu proje derste öğrenilen birçok temel konunun gerçek bir problem üzerinde birlikte kullanılmasını sağlamıştır:

- Histogram equalization / CLAHE** → karanlık framerde yerel kontrast artırımı
- Gürültü filtreleme** → Gaussian blur ile sensör gürültüsünü azaltma
- Renk uzayları** → BGR↔RGB dönüşümü, LAB uzayında CLAHE
- Geometrik dönüşümler** → Resize, koordinat sistemi kuralları (width, height)
- Özellik çıkarımı** → YOLOv8n-Pose ile 17 keypoint, güven eşiği filtreleme
- Normalizasyon** → Hip centering ve shoulder-hip scaling ile pozisyon/ölçek bağımsız temsil
- Zamansal pencereleme** → 30-frame sequence window ile hareketin zamansal bağlamı
- Değerlendirme metrikleri** → Accuracy yerine Precision, Recall, F1 ve AUC-ROC

Tüm sonuçlar `data/sequences/test/` dizinindeki RLVS-only test seti üzerinden hesaplanmıştır.

12. Kaynakça

1. **RLVS Veri Seti:** Soliman, M. M., Kamal, M. H., Nashed, M. A. E., Mostafa, Y., Chawky, B. S., & Khattab, D. (2019). *Violence Recognition from Videos using Deep Learning Techniques*. 9th International Conference on Intelligent Computing and Information Systems (ICICIS), Cairo.
2. **RWF-2000 Veri Seti:** Cheng, M., Cai, K., & Li, M. (2021). *RWF-2000: An Open Large Scale Video Database for Violence Detection*. 25th International Conference on Pattern Recognition (ICPR).
3. **YOLOv8 / Ultralytics:** Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLO* (Version 8.0.0). <https://github.com/ultralytics/ultralytics>
4. **GRU:** Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). *Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation*. EMNLP 2014.
5. **CLAHE:** Zuiderveld, K. (1994). *Contrast Limited Adaptive Histogram Equalization*. Graphics Gems IV. Academic Press.
6. **OpenCV:** Bradski, G. (2000). *The OpenCV Library*. Dr. Dobb's Journal of Software Tools.